

TEMA 9:

Otros Modelos de Sistemas Conexionistas

Prof. Dra. Ana B. Porto Pazos

SISTEMAS INTELIGENTES

2º curso de Grado en Ingeniería Informática

Facultad de Informática



UNIVERSIDADE DA CORUÑA

Otros Modelos de Sistemas Conexionistas

Contenidos del Tema

- a. Redes autoorganizativas.
- b. Otros modelos autoorganizativos:
Crecimiento de redes.

Otros Modelos de Sistemas Conexionistas

Bibliografía

- ▶ P. Isasi, I. M. Galván. Redes de Neuronas Artificiales. Un Enfoque Práctico. Pearson Prentice Hall. 2004.
- ▶ K. Lagus, S. Kaski, and T. Kohonen. Mining massive document collections by the WEBSOM method. Elsevier Science. 2004.
- ▶ Kunze, M. & Steffens, J. Growing Cell Structure and Neural Gas. Incremental Neural Networks. Proceedings of the 4th AIHEP Workshop, Pisa, World Scientific, 1995.

a. Redes Autoorganizativas

Redes Autoorganizativas

Introducción

- ▶ La **autoorganización** en Biología: proceso a través del cual el comportamiento global de un sistema se obtiene solamente como resultado de la interacción local entre los componentes que integran el sistema.
- ▶ La **autoorganización** en Sistemas Conexionistas: consiste en la modificación repetida de los pesos de las conexiones en respuesta a modos de activación y siguiendo unas reglas preestablecidas, hasta el desarrollo final de la estructura o sistema.
 - No existen observadores globales, no existe un “jefe” que determine el comportamiento, no se cuenta con la *salida deseada*.
 - Comportamiento emergente: características surgen de forma inesperada a partir de la interacción entre los componentes del sistema.
 - La red crea su propia representación de la información que recibe mediante la etapa de aprendizaje.
 - La información relevante debe de ser localizada en los propios datos de entrada (redundancia), sin redundancia sería imposible encontrar características en los datos.

Redes Autoorganizativas

Problemas a resolver

- ▶ Si tuviésemos enlaces a 200 páginas web de muchos temas que ya ni identificamos y quisiésemos agruparlas según su temática y además, ordenarlas para hacer un índice en el que apareciesen contiguos los temas relacionados ¿qué programa usaríamos para conseguirlo?
- ▶ Si tuviésemos 1000 fotos de la cara de personas con distintos rasgos (no sabemos cuánto de distinto) y quisiésemos organizarlas por rasgos y similitudes ¿con qué software podríamos hacerlo automáticamente?
- ▶ Si tuviésemos que organizar un tour por un museo, de manera que los visitantes pudiesen visitar sus 40 salas, recorriendo el mínimo trayecto posible hasta volver a la entrada ¿cómo calcularíamos la visita óptima?

Redes Autoorganizativas

Problemas a resolver


- ▶ El reconocimiento automático, descripción y agrupamiento de **patrones** son actividades importantes en una gran variedad de disciplinas científicas, como biología, psicología, medicina, inteligencia artificial, etc.
- ▶ **Patrón:** entidad representada por un conjunto de propiedades y las relaciones entre ellas (vector de características). Por ejemplo, un patrón puede ser:
 - Una señal sonora y su vector de características, el conjunto de coeficientes espectrales extraídos de ella (espectrograma).
 - Una imagen de una cara humana, de la cual se extrae el vector de características formado por un conjunto de valores numéricos calculados a partir de la misma.
- ▶ Es importante conocer qué tipo de proceso puede realizar la red autoorganizativa, qué representa la salida de la red y qué problemas puede resolver.

Mapas AutoOrganizativos (SOM)
Self-Organizing Maps

Redes Autoorganizativas

SOM - Mapas autoorganizativos

- ▶ La estructura anatómica e histológica cerebral revela que **la ubicación espacial** de las células nerviosas tiene gran importancia.
 - En la corteza auditiva primaria las neuronas se distribuyen en un mapa según la frecuencia temporal o la tonalidad a la que responden.
 - En la corteza visual las neuronas se organizan en columnas, y en cada columna presentan características similares: selectividad ante la orientación del estímulo.
- ▶ Una de las propiedades importantes del cerebro es el significativo **orden de sus unidades de proceso**.
 - Este orden hace que células estructuralmente idénticas tengan una diferente funcionalidad debida a parámetros internos que evolucionan de forma diferente según dicha ordenación.
 - Propiedad fundamental para la representación de imágenes visuales, abstracciones, etc.



Redes Autoorganizativas


SOM - Mapas autoorganizativos

- ▶ La posibilidad de que la representación del conocimiento en una categoría particular pueda **asumir la forma de un mapa de características** organizado geométricamente sobre la corteza del cerebro, ha motivado una serie de investigaciones que han dado lugar a nuevos modelos de redes neuronales artificiales.
- ▶ **La localización** de la neurona en la red, especifica un orden topológico que describe la relación de similitud entre los patrones de entrada.
- ▶ “*El supuesto del procesado inteligente de información puede ser visto como la creación de imágenes simplificadas del mundo real con diferentes niveles de abstracción, en relación a un subconjunto particular de datos observables*” [T. Kohonen].

Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen


- ▶ El científico finlandés Teuvo Kohonen diseñó en 1982 un modelo llamado **mapa autoorganizativo de características** que consiste en una red de neuronas de 2 capas: capa de entrada y capa de competición (salida).
- ▶ Modelo de red neuronal con capacidad para formar mapas de características, simulando los mapas topológicos de los fenómenos sensoriales existentes en el cerebro, a través de una organización matricial de neuronas artificiales, que permite:
 - Conseguir un modelo simplificado de los datos de entrada.
 - Obtener un mapa que muestra gráficamente las relaciones existentes entre los datos, preservando su topología
 - Proyectar datos altamente dimensionales a un esquema de representación de baja dimensión: representar conjuntos de datos de gran número de atributos en mapas 2D.
 - Encontrar similitudes en los datos: visualmente podemos detectar de forma rápida cómo quedan agrupados patrones con valores próximos entre sí (Ej. color rojo).



Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

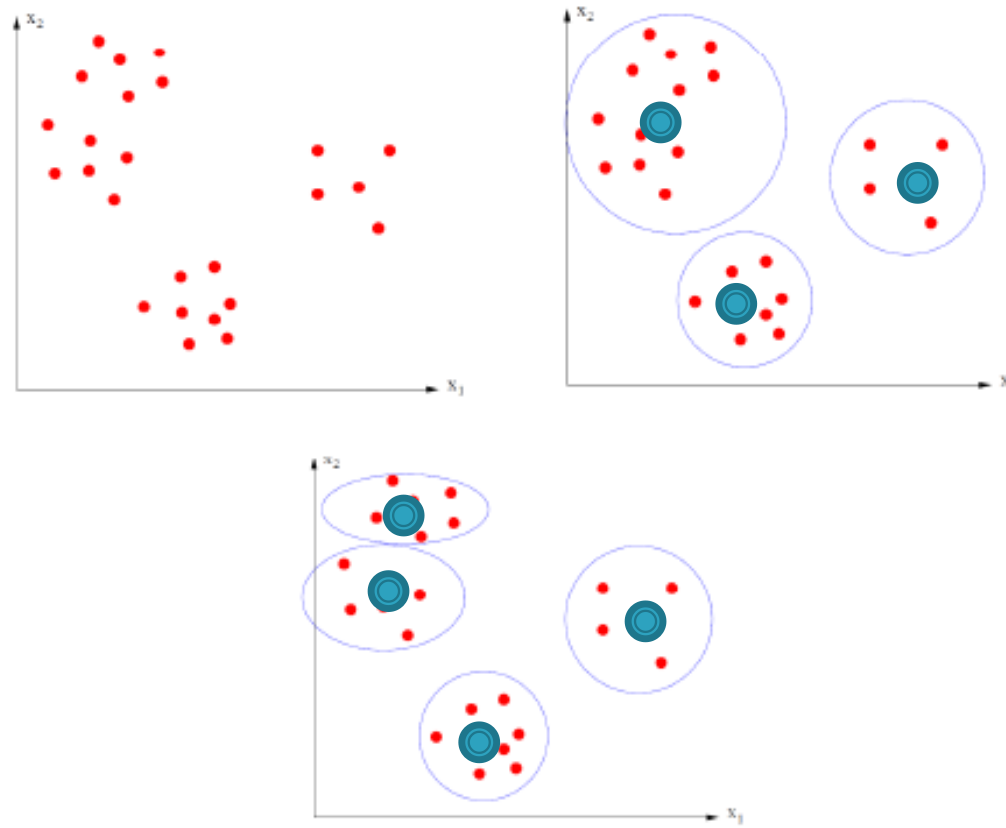
- ▶ Características principales:
 - Son redes no supervisadas.
 - **Aprendizaje competitivo:** las células compiten por aprender (por modificar sus pesos), solo hay una célula ganadora:
 - Se actualizan los pesos de la neurona ganadora para acercarlos al patrón de entrada.
 - Así se van asociando a cada neurona de la capa competitiva, un grupo de patrones de entrada similares, generando *clusters* o grupos.
 - Los pesos de las neuronas serán los prototipos, centros o centroides de los *clusters*.



Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

- *Clusters* o grupos.
 - Los pesos de las neuronas serán los prototipos, centros o centroides de los *clusters*.



Ejemplo simple de red SOM


Conjunto de patrones del problema:

P1 (0,2 0,5)

P2 (0,1 0,3)

P3 (0,9 0,4)

Pn (0,5 0,1)



Ejemplo simple de red SOM


Conjunto de patrones del problema:

P1 (0,2 0,5)

P2 (0,1 0,3)

P3 (0,9 0,4)

Pn (0,5 0,1)



Ejemplo simple de red SOM


Conjunto de patrones del problema:

P1 (0,2 0,5)

P2 (0,1 0,3)

P3 (0,9 0,4)


Pn (0,5 0,1)



Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

- ▶ Características principales:
 - Presentan una topología predefinida de neuronas en el mapa, el aprendizaje conserva la **relación topológica** (orden topográfico).
 - La **vecindad** entre neuronas preserva las relaciones topológicas: las neuronas cercanas responden ante patrones similares.
 - Se puede definir para cada célula de la capa competitiva el conjunto de células próximas que serán sus vecinas (según arquitectura uni, bi o n-dimensional de la capa)



Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

- ▶ Se trata de categorizar los datos de entrada, agrupar los datos similares:
 - Se persigue que patrones parecidos hagan reaccionar a las mismas neuronas.
 - Cada neurona se especializa en determinados patrones de entrada.
 - Cada grupo de patrones estará representado por un **prototipo** (pesos de la neurona).
 - El sistema debe relacionar cada prototipo con los patrones de entrada que representa.
 - Cada prototipo será utilizado, una vez entrenada la red, para categorizar patrones de datos nuevos y desconocidos.
- ▶ En el aprendizaje competitivo:
 - Si un patrón nuevo pertenece a una categoría reconocida previamente, entonces la inclusión de este nuevo patrón a esta categoría o clase, matizará la representación de la misma.
 - Si el nuevo patrón no pertenece a ninguna de las categorías reconocidas anteriormente, entonces la estructura y los pesos de la red neuronal serán ajustados para reconocer a la nueva categoría.


Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

- ▶ La capa de entrada recibe la señal de entrada a la red.
 - La **dimensión** de la entrada depende del número de atributos que tengan los patrones de entrada, si n atributos, entonces: $e = \{e_1, \dots, e_n\}$.
 - Cada neurona de la capa de entrada **se conecta con todas** las neuronas de la capa de competición (no hay conexiones entre las neuronas de competición).
 - Si hay m neuronas en la capa de competición, los pesos de las conexiones entre las dos capas se definen mediante una matriz (n, m) .
 - El **vector de pesos** de cada neurona de la capa de competición tendrá el mismo n° de componentes que el vector de entrada.
 - Al tener la misma dimensión, se pueden **comparar entre sí** los dos vectores, definiendo una función de distancia entre ellos.
 - Los mapas de Kohonen utilizan usualmente la distancia euclídea, la salida de las neuronas de la capa de competición se calcula aplicando dicha función de distancia:

$$\tau_j = \sqrt{\sum_{i=1}^n (e_i - \mu_{ij})^2}$$

- ▶ τ_j – salida de la neurona j
- ▶ e_i – entrada i
- ▶ μ_{ij} – peso de e_i a neurona j



Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen


- ▶ **Funcionamiento del modelo:**
 - ▶ **FASE APRENDIZAJE**
 - ▶ **OBJETIVO:** Acercar los pesos a los vectores/patrones de entrada.
 - ▶ **MODO OPERACIÓN**
 - ▶ Con la red entrenada, utilizarla para categorizar patrones y obtener su prototipo.

Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

► Funcionamiento del modelo - FASE APRENDIZAJE:

OBJETIVO: Acercar los pesos a los vectores de entrada.



- Los pesos de las conexiones se inicializan aleatoriamente al principio de la fase de aprendizaje.
- Se introducen todos los patrones de entrenamiento un número suficiente de veces.
- Cada vez que la red recibe un patrón o vector de entrada, se calcula la salida de todas las células de la capa de competición (cálculo de distancias).
- Gana la célula de **menor distancia** con ese vector de entrada. Dicha célula tendrá salida 1 y el resto salida 0.
- Por tanto, los **pesos de la neurona ganadora** se modifican siguiendo la ecuación siguiente, donde α es la tasa de aprendizaje, que habitualmente decrece con el tiempo (primero tasa elevada y luego baja) hasta llegar a 0 o al final de las iteraciones de entrenamiento (finaliza el aprendizaje):

$$\mu_{ij}(t + 1) = \mu_{ij}(t) + \Delta\mu_{ij}$$



$$\Delta\mu_{ij} = \alpha(e_i - \mu_{ij})$$

Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

► Funcionamiento del modelo - FASE APRENDIZAJE (vecindad):

- **Vecindad:** indica qué otras células aprenden cuando se activa una neurona.



- Los pesos de las conexiones de las células vecinas se modifican en función de la distancia, con lo que α se dividirá por una función distancia de vecindario cuando se aplique a las vecinas la modificación de los pesos, siendo c_i la célula ganadora y c_j la vecina:

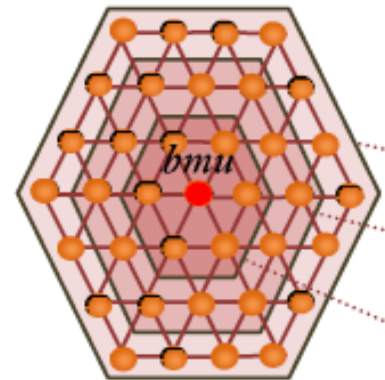

$$\Delta \mu_{ij} = \frac{\alpha}{d(c_i, c_j)} (e_i - \mu_{ij})$$

- La **vecindad** también se modifica con el tiempo o el número de iteraciones, inicialmente es mayor y se va reduciendo para estabilizar el aprendizaje.

Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

- ▶ **Funcionamiento del modelo - FASE APRENDIZAJE (vecindad):**
 - ▶ La **vecindad** se modifica con el tiempo o el número de iteraciones, inicialmente es mayor y se va reduciendo para estabilizar el aprendizaje.
 - ▶ Ejemplos de evolución del área de vecindad en distintas iteraciones del proceso de entrenamiento:



Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

► **Funcionamiento del modelo - FASE APRENDIZAJE (vecindad):**

Vecindad: regulada por 3 parámetros:

- ▶ Radio de vecindad: amplitud del alcance de las neuronas afectadas por vecindad
- ▶ Topología de la vecindad: neuronas que se consideran vecinas inmediatas
- ▶ Función de vecindad: cuantificación del grado de vecindad proporcional a distancia a la ganadora (centro).
- ▶ Las neuronas pertenecientes a la región de vecindad o interés del ganador son también modificadas para conseguir que la red cree **regiones** que respondan a valores muy próximos al del patrón de entrenamiento.
- ▶ Como consecuencia, patrones de entrada que no se hayan usado para el entrenamiento serán similares a algún vector de pesos de una región y serán correctamente agrupadas -> **demuestra la Generalidad de esta estructura.**
- ▶ 2 ideas centrales en las que se basa Kohonen para desarrollar sus estructuras usando aprendizaje autoorganizativo y competitivo: “*El proceso de adaptación de pesos y el concepto de geometría topológica de elementos de proceso*”

Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

► Funcionamiento del modelo - FASE APRENDIZAJE(algoritmo)

Tendencia del proceso de aprendizaje: cada neurona tiende a colocarse en el centroide de aquellos grupos de ejemplos de entrada para los cuales es la neurona ganadora

1. Inicializar pesos

- Asignar a los pesos valores pequeños aleatorios

2. Presentar una entrada

- El conjunto de aprendizaje (ξ) se presenta repetidas veces hasta llegar a la convergencia de la red
- Actualizar α (ir reduciendo su valor)

3. Propagar el patrón de entrada hasta la capa de competición

- Obtener los valores de salida (distancias) de las neuronas de dicha capa


4. Seleccionar la neurona ganadora (BMU – *best-matching unit*)

- La de menor distancia al patrón

5. Actualizar conexiones entre capa de entrada y la BMU

- Actualizar también los pesos de sus vecinas según el grado de vecindad
- 1. Fase Ordenación: valores altos de α y radio vecindario. 2. Fase Convergencia: valores bajos

6. Si α se mantiene por encima del umbral de parada (o no se ha llegado a T iteraciones), volver a 2, en caso contrario FIN



Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

► Funcionamiento del modelo – Validar calidad del SOM

1. Se repite el proceso de entrenamiento N veces, cada una de ellas con una configuración inicial diferente de los vectores de pesos sinápticos.
2. Para determinar la calidad del SOM y ayudar en la selección de sus parámetros de tamaño y aprendizaje adecuados se emplean el ***error de cuantización medio*** y ***medidas de preservación de la topología***.
 - Se calcula el error de representación para cada uno de los mapas obtenidos y se selecciona el de menor error.
 - Este error de cuantización medio, evalúa el grado de adaptación del mapa SOM a los datos de entrada, siendo mejor el que menor error obtenga entre las conexiones de las BMU y los vectores (patrones de entrada) a los que representa.
 - Una vez entrenada la red, se vuelven a procesar todos los patrones de entrenamiento, obteniendo para cada uno de ellos la neurona BMU, y se calcula el error de cuantización medio como:

$$E = \frac{1}{N} \sum_{i=1}^N \|e_i - w_{bmu}\|^2 \quad \text{siendo N el número de vectores de entrada.}$$

Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen

- ▶ **Funcionamiento del modelo – Validar calidad del SOM**
 - ▶ Además, se emplean *Medidas de preservación de la topología*:
 - El error de cuantización indicado, no tiene en cuenta la estructura del mapa de la capa competitiva de la SOM, la información sobre las relaciones existentes en los patrones de entrenamiento.
 - Por lo que también es necesario medir la adaptación de la topología de la red a las características topológicas del espacio de datos de entrenamiento.
 - Cuando una red SOM converge, la distribución de la estructura regular definida en la capa de salida se suele distorsionar, pudiendo aparecer efectos adversos (neuronas que representan a datos de entrada similares pero que están alejadas, etc.)
 - En este caso el error de cuantización puede ser bueno, pero a pesar de ello existir problemas.
 - Es necesario emplear además **medidas de preservación de la topología para validar la calidad** de la red entrenada que permitan comprobar que:
 - Los prototipos de las neuronas que se encuentran próximas en el mapa también se encuentren próximos en el espacio de entrada de datos.
 - Los datos de entrada similares queden representados por neuronas próximas en el mapa. (Existen varias adecuadas según los problemas. Ej. Matrices fuerza de conectividad)

Redes Autoorganizativas

SOM - Mapas autoorganizativos de Kohonen


- ▶ **Funcionamiento del modelo - MODO OPERACIÓN:**
 - ▶ Se introduce un patrón de entrada para conocer su prototipo.
 - ▶ Cada neurona de salida calcula la similitud entre el vector de entrada y su vector de pesos.
 - ▶ Vence la neurona con mayor similitud: será la categoría seleccionada por la red para agrupar ese patrón de entrada o el prototipo seleccionado.

Redes Autoorganizativas

Mapas auto-organizativos




- ▶ Representación geométrica:
- ▶ Los ejemplos y los prototipos (pesos de las neuronas de la capa competitiva) se pueden representar como puntos en un espacio n-dimensional.




Redes Autoorganizativas

Mapas auto-organizativos




- ▶ Representación geométrica:
- ▶ Las coordenadas de los prototipos son los pesos de las células de la capa competitiva.





Redes Autoorganizativas

Mapas auto-organizativos




- ▶ Una demostración visual del funcionamiento de la red la ofrecen los *mapas topológicos bidimensionales de Kohonen*:
 - ▶ Distribuyen los elementos de la red (puntos que representan a los pesos) a lo largo de un conjunto de patrones de entrada.
 - ▶ Cuando las entradas son de 2 atributos o 3 (2D y 3D), los pesos representados por puntos coordenados en 2D se van aproximando a los datos de entrada que están ahí representados, en un cuadrado 2D, por ejemplo.
 - ▶ Se representan los puntos (pesos de las neuronas) conectados con los de sus vecinas, no es una conexión física, sino una relación entre neuronas a efectos de vecindario (conexión topológica).
 - ▶ Grado de Vecindad: número de células que habrá que recorrer para llegar de una célula a otra.





Redes Autoorganizativas

Mapas auto-organizativos




- ▶ *Mapas topológicos bidimensionales de Kohonen:*
 - ▶ A medida que se introducen los patrones de entrada, la red los va aprendiendo, varía el valor de sus conexiones, trasladándose hacia las entradas.
 - ▶ Donde hay mayor densidad de entradas, habrá más densidad de “puntos conexiones - neuronas”
 - ▶ Se comprueba si la red está comportándose correctamente si no se cruzan las líneas.






Redes Autoorganizativas

Mapas auto-organizativos



- ▶ Otro ejemplo (distribución toroidal de patrones de entrada) con la misma red anterior:
 - ▶ Puede darse el caso de que haya puntos que no estén asociados a ningún vector de entradas.
 - ▶ En este caso esos prototipos que no representan a ningún ejemplo de entrada se pasarán por alto en la fase de operación con entradas desconocidas.
 - ▶ Siguiendo las conexiones topológicas se puede saber qué prototipos comparten características similares.



Redes Autoorganizativas

Mapas auto-organizativos

- ▶ **Aplicaciones:** Tipos de problemas que pueden resolver los SOM, condicionará cómo se interprete lo que representa la salida de un SOM
- ▶ **Agrupamiento de patrones (clustering):** A partir de un conjunto de entrada se desea determinar si se puede dividir ese conjunto en diferentes grupos o *clusters* con un centro o patrón del *cluster*. Ej. Extraer temas de documentos.
 - Permite separar datos en grupos (a priori no sabemos cuántos existen)
 - Facilita indicar a qué grupo pertenece cada dato de entrada
 - Determinando su neurona ganadora
 - Permite caracterizar cada grupo
 - Mediante los pesos de la neurona que representa ese grupo
- ▶ **Prototipado:** Similar al anterior, en lugar de interés por los grupos, interesa obtener un prototipo del grupo al que pertenece cada patrón de entrada.
 - Usa los pesos de la ganadora para determinar ese prototipo
 - Ej. Compresión de imagen.

Redes Autoorganizativas

Mapas auto-organizativos

▶ Aplicaciones:

- ▶ **Análisis de componentes principales:** Se trata de detectar qué elementos/atributos del conjunto de entrada caracterizan en mayor grado ese conjunto de datos. Seleccionar las entradas de la red realmente necesarias, sin pérdida de información – supone reducción de dimensionalidad.
 - Las demás entradas podrán eliminarse sin una pérdida significativa de información.
- ▶ **Extracción y relación de características:** Se pretende organizar los vectores de entrada en un mapa topológico
 - A partir de la red entrenada, patrones parecidos producirán respuestas similares en neuronas cercanas.
 - Si existe una organización global de patrones de entrada, se verá reflejada en la salida de la red.
 - Se ubican entradas parecidas y/o relacionadas en zonas próximas de la red
- ▶ Estas categorías no son disjuntas. Ej: componentes principales para reducir la dimensionalidad y después aplicar clustering.

Redes Autoorganizativas

Mapas auto-organizativos

Ejemplo Aplicación:


- ▶ **Problema del Viajante.** Clásico en computación debido a su complejidad (np-completo su complejidad es factorial), muchos problemas exigen encontrar una solución al TPS (traveling salesman problem).
- ▶ Recorrido más corto que debería hacer un viajante de comercio para visitar **n** ciudades una sola vez, volviendo por último a la primera (todas las ciudades tienen conexión con todas las demás y se conocen las distancias).
- ▶ **SOLUCIÓN:** Lista ordenada de ciudades visitadas una sola vez, que empiece y acabe en la misma.
 - ▶ La forma de encontrar la solución óptima es probar todas las posibles combinaciones y quedarse con la que genere un camino más corto.
 - ▶ Como todo problema de combinatoria, esta solución es ineficaz en cuanto aumenta un poco el nº de ciudades a visitar.

Redes Autoorganizativas

Mapas auto-organizativos




Ejemplo Aplicación:

Lineal



► **Problema del Viajante.** Solución con mapa Kohonen:

- Las ciudades situadas con sus coordenadas en un mapa bidimensional son el espacio de vectores de entrada.
- Los puntos representando pesos de las neuronas de la capa competitiva se generan con vecindario unidimensional.
- El entrenamiento finaliza cuando los valores de los pesos de las neuronas (similar a coordenadas x, y) sean los mismos de las ciudades (se va ajustando tasa de aprendizaje y vecindad)




Redes Autoorganizativas

Mapas auto-organizativos

Ejemplo Aplicación:

▶ Problema del Viajante.

- ▶ Se inicia el entrenamiento con un n° de células mayor o igual que el de ciudades ($3*N$), para agilizar el entrenamiento.
 - ▶ Las unidades de proceso van a estar colocadas sobre una circunferencia e igualmente espaciadas, de manera que la circunferencia determinará la ruta a seguir
 - ▶ En la figura se presenta **la trayectoria de los pesos sinápticos** y el resultado obtenido cuando el número de ciudades es 15 y el número de unidades de proceso 45.
- ▶ Al final 15 neuronas tendrán los mismos pesos que las coordenadas de las ciudades (se va ajustando tasa de aprendizaje y vecindad).
 - ▶ Buen ejemplo de la importancia de las características topológicas de la red, **la solución** no está en la lista de puntos y a qué grupo pertenecen, ni en su posición, si no **en el vecindario de las ciudades, el orden y quiénes son sus vecinos.**







Redes Autoorganizativas

Mapas auto-organizativos

Ejemplo Aplicación:

▶ **Delimitar un vaso sanguíneo.** Solución con mapa de Kohonen:

- ▶ Se dispone de 322 puntos (x, y) que configuran el contorno difuso de un vaso sanguíneo en una mamografía.
- ▶ Se trata de diseñar una red neuronal que construya el contorno poligonal de 30 vértices que “mejor” se ajusta al contorno del vaso sanguíneo.
- ▶ Como no conocemos la posición ni la orientación del vaso sanguíneo, las células se colocan sobre una circunferencia igualmente espaciadas.
- ▶ Los vectores sinápticos serán atraídos por los puntos que configuran el contorno del vaso sanguíneo y nos darán los vértices del contorno poligonal.

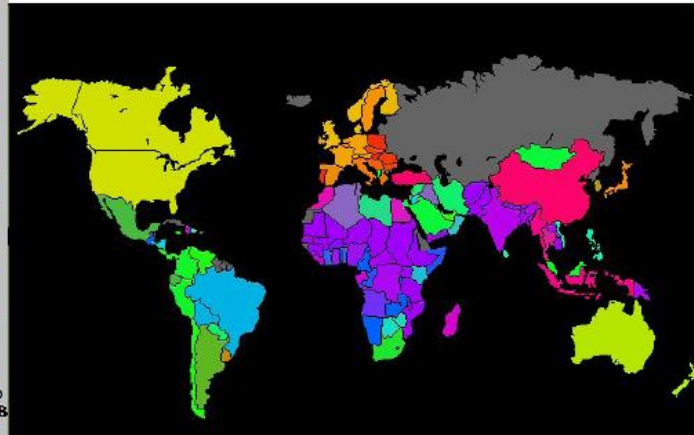



Redes Autoorganizativas

Mapas auto-organizativos

Ejemplo Aplicación:

- ▶ **Mapa de la “pobreza” mundial** (Helsinki University of Technology)
<http://www.cis.hut.fi/research/som-research/worldmap.html>
 - ▶ Países descritos mediante vectores de 39 indicadores de calidad de vida (nivel educativo, sistema sanitario, etc).



- ▶ Después del entrenamiento del SOM:
 - ▶ Cada neurona de competición se “especializa” en un país.
 - ▶ Países con niveles de riqueza similares activan neuronas próximas.

Redes Autoorganizativas

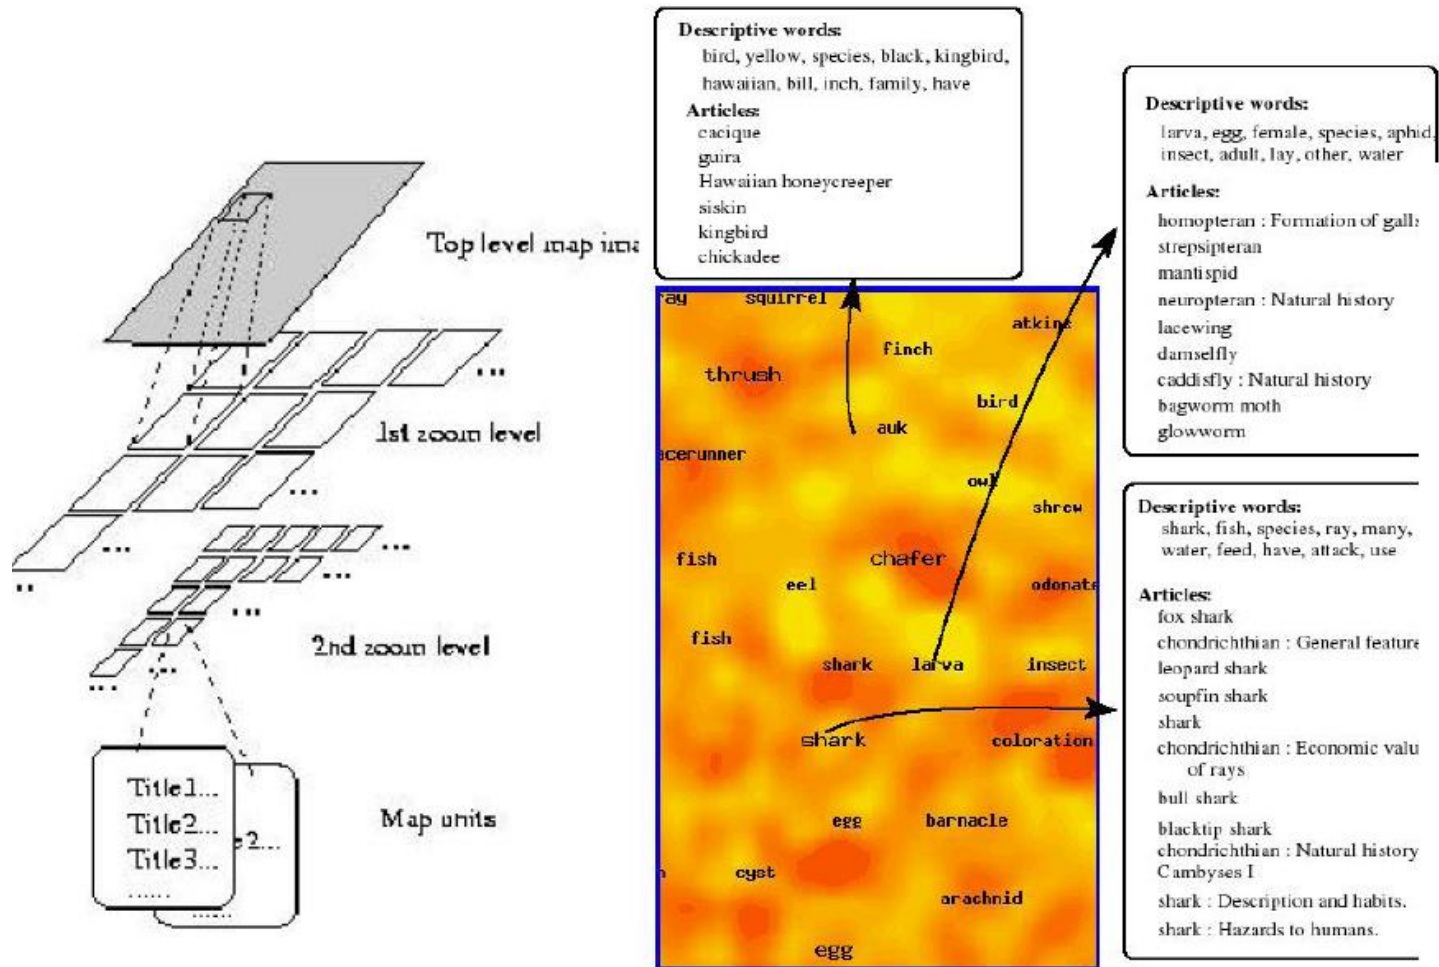
Mapas auto-organizativos

Ejemplo Aplicación:

- ▶ **WebSOM:** Agrupación de documentos y reducción de dimensionalidad. SOM para la organización de grandes colecciones de documentos textuales en Internet. <http://users.ics.aalto.fi/tho/stes/step96/lagus/>
- ▶ Organiza los documentos estructurándolos en un “mapa” en función de su contenido.
- ▶ Documentos similares (misma temática) se ubican en zonas próximas del “mapa”.
- ▶ Permite la navegación por ese “mapa de documentos” (estructuración en niveles).

Redes Autoorganizativas

Mapas auto-organizados: WebSOM



Redes Autoorganizativas

Mapas auto-organizativos

▶ Ventajas de SOM:

- ▶ Transparentes a los datos de entrada (se limitan a comparar vectores).
- ▶ Adaptación local de los vectores de referencia a la densidad de probabilidad de los datos
- ▶ Facilidad de visualización gracias a la malla que conforma la topología de la capa de salida.
- ▶ Facilidad de integración con otras técnicas.

Redes Autoorganizativas


Mapas auto-organizativos

► Limitaciones o inconvenientes de SOM:

- Necesidad de determinar la arquitectura exacta de la red antes de someterla al entrenamiento, así como la imposibilidad de modificar su diseño durante el mismo.
 - Dimensión de la red (se tiene que fijar a priori - más neuronas > tiempo entren.)
 - Velocidad y vecindad del aprendizaje
- Algunas neuronas pueden no ser entrenadas: pueden existir vectores de pesos muy distanciados de las entradas, con lo cual, nunca ganarán (este tipo de neurona es común cuando se aplica el algoritmo a redes y conjuntos de datos muy grandes).
 - Patrones cercanos activan neuronas distantes
 - Neuronas vecinas pueden ser activadas por patrones distantes
- No se puede medir hasta que punto es buena la neurona vencedora, la neurona que gana es la más cercana a la entrada, pero no podemos cuantificar si está cerca o lejos de los pesos adecuados.
- Importantísimo en estos sistemas: la inicialización de pesos.
- Son caros computacionalmente cuando se incrementa la dimensión de los datos.

Redes Autoorganizativas

Mapas auto-organizativos



Problemas de las SOM. Los puntos azules identifican a los patrones de entrenamiento (puntos en el plano con una distribución en dos círculos separados). Los puntos rojos identifican a las neuronas de la red SOM entrenada, organizadas en 15 filas por 15 columnas y las líneas identifican las conexiones de vecindad entre ellas. Efecto bordes: las neuronas exteriores no representan fielmente la distribución de probabilidad de los puntos a los que identifican. Efecto de contracción: las neuronas exteriores sufren un efecto imán hacia los puntos centrales. Neuronas interpolantes: las neuronas que aparecen entre ambos círculos se encuentran en zonas del espacio de entrada con densidad de probabilidad nula.

7.2 Otros modelos autoorganizativos: Crecimiento de Redes

Growing Cell Structures (GCS)

Growing Neural Gas (GNG)

Redes Autoorganizativas

Crecimiento de Redes

- ▶ A pesar de las interesantes características del SOM de Kohonen, en la década de los años 90 se presentaron nuevos modelos de mapas autoorganizativos que pretendían solucionar los inconvenientes existentes.
- ▶ Al trabajar con SOM hay que definir previamente la estructura de la red.
 - Esta definición suele ser bastante compleja por la falta de información que normalmente se tiene sobre el espacio de entrada.
 - La topología estática de los SOM limita a veces su capacidad para ajustarse a los datos.

Redes Autoorganizativas

Crecimiento de Redes


- ▶ Para solucionar este problema aparece una nueva filosofía a la hora de aplicar redes de neuronas a problemas de agrupamiento: **Crecimiento de Redes**.
 - Se trata de iniciar el aprendizaje con un conjunto pequeño de elementos de proceso (EP) y que sea la propia red la que determine de forma autónoma su estructura, a partir de los datos de entrenamiento se generan los EP necesarios y las conexiones entre ellos.
 - Esta característica permite obtener modelos simplificados de los datos **con mejores medidas de la preservación de la topología** que las redes de Kohonen.
 - Se construyen partiendo de estructuras básicas (*incluso hipertetraedros de dimensión k*).
 - Para llegar a la estructura final de la red se realiza un proceso donde se van añadiendo y borrando EP y conexiones, al tiempo que se sigue un proceso de autoorganización similar al que se produce en el modelo propuesto por Kohonen.
 - Incluso pueden existir varias mallas de vecindad separadas en la capa de salida.
 - Mantienen la capacidad de ofrecer un mapa para visualizar las relaciones existentes entre los patrones de entrada.

Redes Autoorganizativas

Crecimiento de Redes

► Inserción de Neuronas:

- Para poder determinar dónde y cómo se ha de incluir una nueva neurona se introduce un nuevo concepto, **valor *resource*** (error de cuantización): valor asignado a cada neurona que medirá lo lejos que se encuentra de la estructura ideal (se obtiene del error con respecto a los patrones de entrada).
 - Este valor irá variando a medida que la red vaya evolucionando.
- Siempre después de un n° constante de “modificaciones de pesos” sobre la red actual, se analizará la necesidad o no de añadir nuevas neuronas.
 - Añadir un nuevo elemento a la red conlleva el adecuar las conexiones entre los elementos vecinos para que la nueva estructura sea consistente.
- Nueva neurona: tanto su vector de pesos como su valor *resource*, se calcularán a partir de los parámetros de sus neuronas vecinas.




Redes Autoorganizativas

Crecimiento de Redes

▶ Borrado de Neuronas:

- Cuando el conjunto de patrones o vectores de entrada que pueden activar una determinada neurona tienen una probabilidad de aparición muy baja, podemos estimar que el coste de mantener esa neurona dentro de la estructura de la red no compensa y por lo tanto, se elimina.



Redes Autoorganizativas

Growing Cell Structures (GCS)

- ▶ Entre los modelos de crecimiento de redes, se creó el modelo conocido como Growing Cell Structures (GCS), planteado por B. Fritzke en 1994.
- ▶ La red GCS ofrece como principal ventaja frente al modelo de Kohonen la dinamicidad de la arquitectura de la capa de salida de la red durante la fase de entrenamiento de la misma.
 - Orientada a cuantificación vectorial – clustering (no supervisada)
 - La adición de neuronas (EP) se realiza en las regiones con más patrones de entrenamiento.
 - Su estructura de la capa de salida es simple y está formada por **estructuras k-dimensionales básicas**.
 - El número de parámetros de entrenamiento y la complejidad de su configuración son normalmente bajos, aunque a veces difíciles de interpretar (inconveniente).

Redes Autoorganizativas


Growing Cell Structures (GCS)

- ▶ El **objetivo** es conseguir una estructura cuyos vectores de entrenamiento se distribuyan de acuerdo a la distribución (desconocida) de los vectores de entrada.
 - Patrones/vectores de entrada similares se agruparán en neuronas topológicamente próximas.
 - Neuronas vecinas agruparán vectores de entrada similares.
 - Regiones del espacio de entrada con una densidad alta serán representadas por un número elevado de neuronas y viceversa.

Redes Autoorganizativas

Growing Cell Structures (GCS)

- ▶ Durante el proceso de adaptación de pesos de la red, se insertan y eliminan neuronas/conexiones de vecindad asegurando que la capa de salida queda compuesta por **estructuras k-dimensionales básicas**.
- ▶ Se muestran estructuras básicas para k igual a 1 (a - segmento), 2 (b - triángulo) y 3 (c - tetraedro).
- ▶ k dimensiones (hipertetraedros). Existirán: $k+1$ vértices y $(k+1)*k/2$ aristas.




Redes Autoorganizativas

Growing Cell Structures (GCS)

- ▶ Exceptuando la topología de la capa de salida, el resto de la arquitectura de una red GCS es idéntica a la del modelo de Kohonen (figura con k=2).
- ▶ Respecto a la dinámica de procesamiento de vectores, el entrenamiento es competitivo, pero cada neurona tiene además de vecinas y vector de pesos, un **contador** que almacena el **error de cuantización**: cuadrado de la distancia euclídea al patrón de entrada cuando dicha neurona es ganadora (BMU).
- ▶ Se utilizan **2 tasas de aprendizaje**: una para modificar los pesos de la BMU y otra para los de sus vecinas inmediatas.

$$\Delta w_{bmu} = \alpha_1(e - w_{bmu}); \Delta w_n = \alpha_2(e - w_n)$$


- ▶ No se hace uso de una función de vecindad que varíe según avanza el entrenamiento, solo se modifican los pesos de las vecinas inmediatas.




Redes Autoorganizativas

Growing Cell Structures (GCS)


- ▶ Ejemplo:
 - Evolución del entrenamiento de una red GCS bidimensional con parámetros: $k=2$ y $\lambda=100$




0




100




400



1000



4000

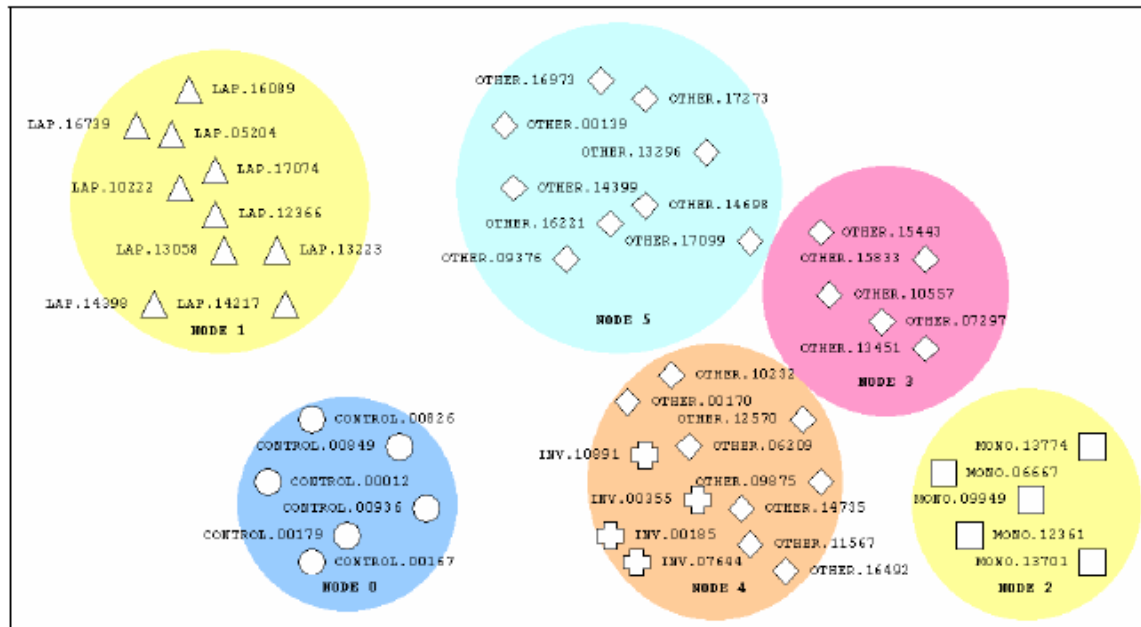


10000

Redes Autoorganizativas

Growing Cell Structures (GCS)

- ▶ **Aplicación:** Diagnóstico de tumores en datos de microarrays de ADN (alta dimensión).
 - Datos de microarrays de ADN pertenecientes a muestras de médula ósea de 43 pacientes adultos con cáncer, más un grupo de seis casos correspondientes a personas sanas.



Redes Autoorganizativas


Growing Neural Gas (GNG)

- ▶ En 1995 Fritzke planteó el modelo Growing Neural Gas (GNG) Gas Neuronal Creciente.
- ▶ Es otro modelo de red autoorganizaiva dinámica, pero a diferencia de la GCS no mantiene en el proceso de inserción y eliminación de neuronas ninguna estructura k-dimensional estricta o fija en la capa de salida de la red.
 - Se adapta a diferentes dimensiones y puede ir variando la dimensión de la estructura dimensional que emplea en función de los datos de entrada.
 - A diferencia de la GCS, la GNG trabaja más con **aristas** que con triángulos.
 - Con la inserción y borrado de aristas la red trata de adaptarse a los vectores de entrada.
 - Los parámetros introducidos son constantes en el aprendizaje.
 - En los mapas de Kohonen, las conexiones de vecindad son laterales formando una cruz en cada unidad, en GNG, una unidad puede tener mucho más de cuatro vecinos, generando diversas figuras geométricas.
 - Se trata por tanto, de una red con mayor capacidad de aprendizaje.

Redes Autoorganizativas

Growing Neural Gas (GNG)



- ▶ Se adapta a diferentes dimensiones y puede ir variando la dimensión de la estructura dimensional que emplea en función de los datos de entrada.



Redes Autoorganizativas

Growing Neural Gas (GNG)

- ▶ Aplicación de GNG: *The two Spiral Benchmark*
 - La separación de dos espirales entrelazadas es un problema frecuentemente referenciado para resolver mediante modelos de RNAs.
 - Una GNG los separa perfectamente.



Redes Autoorganizativas

Growing Neural Gas (GNG)

- ▶ Aplicación de GNG: *Lectura óptica de caracteres (Optical Character Reading - OCR)*
 - La segmentación de gráficos y caracteres es la primera tarea a realizar por algunos algoritmos de OCR.
 - El GNG es capaz de segmentar ítems de imágenes escaneadas en un modo de aprendizaje no supervisado: no hay largos ciclos de entrenamiento con el fin de aprender formas de caracteres de antemano, ni es necesario definir ventanas pixeladas movidas a través de la imagen.
 - Segmenta los “dibujos” y las líneas emergentes entre las “neuronas” y sus ángulos, permiten fácilmente el reconocimiento de caracteres con un clasificador.



Redes Autoorganizativas

Crecimiento de Redes

▶ Resumen características:

- La topología autoadaptativa de la red es altamente independiente del usuario.
- La estructura de la capa de salida de la red queda automáticamente establecida por los datos de entrada.
- Los parámetros de entrenamiento que hay que establecer son relativamente pocos y constantes, en contraste con los parámetros de área de vecindad o factor de aprendizaje dependientes del tiempo en el modelo de Kohonen.
- La capacidad de insertar y eliminar neuronas ofrece la posibilidad de obtener mejores estimaciones de la densidad de probabilidad del espacio de entrada que los de otras redes autoorganizativas, al no posicionar neuronas en zonas del espacio de entrada con baja o nula densidad.
- Tienen suficiente capacidad para procesar espacios de datos de gran dimensión, tareas de descubrimiento de conocimiento como: aproximación de funciones, visualización (extracción de áreas o puntos en imágenes cerebrales), clustering (en datos bioinformáticos), etc.
- Aunque originalmente el entrenamiento es no supervisado, puede adaptarse a procesos de aprendizaje supervisado para **clasificación**.